



Generación de Datos Financieros sintéticos

Albert Martin & Jesús Bussión

Objetivos

- Probar diferentes métodos de generación de datos sintéticos basados en redes neuronales.
- Analizar el efecto de uso de datos sintéticos en el entrenamiento de modelos.



Table of contents

01

**Definición del
problema financiero**

02

**Diseño y entrenamiento de
Downstream baseline**

03

**Diseño y entrenamiento
de modelos generativos**

04

**Generación de
datasets sintéticos y
entrenamiento con
barrido**

05

**Backtesting y
Resultados**

06

***GAN
Cuántica**

A low-angle, black and white photograph of several tall skyscrapers reaching towards the sky. The perspective creates a sense of height and scale. The buildings are dark, and the sky is a lighter, hazy grey.

01

Definición
del problema
financiero

Problema

¿Cómo predecimos si en las próximas semanas el mercado entrará en un régimen de estrés cuando los episodios históricos de ese estrés son muy pocos para entrenar un modelo fiable?

Solución

Generar ventanas sintéticas de estrés y mezclarlas con pocos datos reales para entrenar un clasificador que anticipe episodios de alta volatilidad de cartera.

Datos Utilizados



Seleccionamos **23 activos** del S&P 500.




Período de análisis: **1962 – 2026**.





Convertimos los precios históricos a **retornos logarítmicos**.

Target: régimen de alta volatilidad futura. Los eventos raros vienen en bloques



Los retornos diarios no se comprimen: la curva es casi una recta





**Diseño y
entrenamiento de
Downstream
baseline**

02

Modelo Baseline y Benchmarks



Elaboramos un modelo que nos sirva como **baseline**.



Usamos como métrica principal **PR-ACU** y el **lift**.



Como **benchmarks** usamos:

- Volatilidad realizada.
- Drawdown actual con respecto a la ventana.
- Regresión lineal.



Arquitectura de las CNN

Resumen de las variantes evaluadas, sus diferencias clave y su desempeño.



1. cnn_prof

COPIA FIEL DE VALERO



Qué es

Arquitectura de Valero tal cual.



Qué cambia /
añade

Usa padding="valid".



Por qué
importa

Pierde información temporal en cada capa; tras 3 poolings la secuencia queda muy corta.



2. cnn_raw

MISMA RED, SIN RECORTAR TANTO

La misma arquitectura que cnn_prof.

Solo el padding pasa a "same".

Mantiene mejor la longitud temporal y conserva más contexto de los 60 días.



3. cnn_mag

VE TAMBIÉN EL TAMAÑO DEL MOVIMIENTO

CNN que añade la magnitud explícita del movimiento.

Duplica cada dato con su valor absoluto $|r| \rightarrow [retorno, |retorno|]$. De 23 a 46 canales por día.

Le da la "intensidad del movimiento" sin tener que adivinarla; ayuda a detectar volatilidad.



4. cnn_mag_bn

CON NORMALIZACIÓN POR CAPA

cnn_mag con Batch Normalization después de cada convolución.

Añade normalización por capa para estabilizar activaciones.

Estabiliza el entrenamiento, pero aquí no aporta mejoras relevantes.



5. cnn_mag_gap

RESUMEN CON PROMEDIO GLOBAL

cnn_mag que resume con GlobalAveragePooling1D en vez de Flatten.

Usa promedio global por filtro a lo largo del tiempo.

Reduce parámetros, pero pierde detalle temporal fino que sí importa en este problema.

Selección del modelo downstream

Evaluación en datos **100% reales**




Comparamos todas las arquitecturas con nuestras métricas en el **conjunto de test real**.







Las variantes con **magnitud explícita** muestran el mejor desempeño.



Elegimos **cnn_mag** como modelo final por su equilibrio entre rendimiento, estabilidad y enfoque conceptual.





— loss
— pr_auc
— val_loss
— val_pr_auc

Layer (type)	Output Shape	Param #
input_layer_21 (InputLayer)	(None, 60, 23)	0
magnitude_features_13 (MagnitudeFeatures)	(None, 60, 46)	0
conv1d_63 (Conv1D)	(None, 60, 64)	8,896
activation_63 (Activation)	(None, 60, 64)	0
max_pooling1d_63 (MaxPooling1D)	(None, 30, 64)	0
conv1d_64 (Conv1D)	(None, 30, 128)	24,704
activation_64 (Activation)	(None, 30, 128)	0
max_pooling1d_64 (MaxPooling1D)	(None, 15, 128)	0
conv1d_65 (Conv1D)	(None, 15, 128)	49,280
activation_65 (Activation)	(None, 15, 128)	0
max_pooling1d_65 (MaxPooling1D)	(None, 7, 128)	0
flatten_17 (Flatten)	(None, 896)	0
dense_42 (Dense)	(None, 100)	89,700
dropout_21 (Dropout)	(None, 100)	0
dense_43 (Dense)	(None, 1)	101

A low-angle, black and white photograph of several tall skyscrapers reaching towards a cloudy sky. The perspective makes the buildings appear to converge towards the top of the frame. A white rectangular border is superimposed over the center of the image, containing the title text.

03





Diseño y
entrenamiento
de modelos
generativos

Modelos Generativos

Entrenamos distintos modelos para generar la etiqueta que nos falta: **eventos de alta volatilidad**.

#	Generador	Familia
1	Ruido	Perturbación de datos reales
2	Gaussiano multivariante	Paramétrico / Bayes
3	t-Student multivariante	Paramétrico con colas pesadas
4	Factor de mercado + idio	Un factor común + residuo
5	VAE	Latente probabilístico
6	GAN	Adversarial
7	Autoregresivo	Factorización temporal
8	GAN híbrida cuántica	Bonus (notebook 06)


Convergencia de los generadores entrenables






¿Reproducen los generadores lo que define el estrés de mercado?


(a) Retornos diarios: colas




(b) Volatilidad de la cartera equiponderada




(c) Correlación media entre activos




t-Student #0




t-Student #1




t-Student #2




Factor de mercado #0




Factor de mercado #1



Factor de mercado #2





Los modelos que aciertan a la hora de replicar la volatilidad de cartera están en los *dos extremos* del nivel de coste y sofisticación: el ruido (trivial, no aprende nada) y el factor de mercado + idiosincrático.

The background is a dark, high-contrast aerial photograph of a city grid, showing a dense pattern of streets and building footprints. A thin white rectangular frame is centered on the page, enclosing the main title text.

**Generación de
datasets
sintéticos y
entrenamiento
con barrido**






04

Comparacion entre generadores y densidad de valores sinteticos


- La rejilla esta compuesta por:
- Valores reales (500, 1000, 2000, 4000, todos) $\times$ valores sintéticos (0, 250, 500, 1000, 2000) $\times$ 7 generadores $\times$ 3 semillas
- 450 celdas



Comparación entre modelos generativos



Mejor ganancia relativa en PR-AUC (test) frente a no usar sintéticos





05



Backtesting
y Resultados

¿Ayudan los datos sintéticos?

¿Cuándo, cuánto y con qué generador?

La hipótesis es cuál es el elemento condicionante para que los datos sintéticos ayuden al modelo, y es que si **un generador reproduce la estadística concreta de la que depende la etiqueta, ayuda**, si no, sus muestras pueden parecer realistas pero no ayudan.

Un generador ayuda si reproduce la estadística concreta que define el target



¿Se traduce la mejora estadística en valor financiero?


Resultados del backtest

Estrategia	Sharpe	Máx. drawdown	Tiempo invertido
Buy & hold	0.55	-38.4%	100%
Aleatorio	0.59	-30.8%	92%
Oráculo	1.21	-15.4%	92%
500 reales, sin sintéticos	0.65	-21.4%	96%
500 reales + 1000 ruido	0.71	-15.4%	92%
Todos, sin sintéticos	0.51	-23.0%	94%
Todos + 2000 ruido	0.50	-21.8%	94%

Tres lecturas

- 1 Con datos escasos, los sintéticos mejoran el riesgo:
Sharpe 0.65 $\rightarrow$ 0.71, drawdown -21.4% $\rightarrow$ -15.4% (= oráculo).
- 2 No es solo "estar menos en el mercado":
el control aleatorio (mismo 92% invertido) tiene Sharpe 0.59 y drawdown -30.8%.
- 3 Coherente con PR-AUC:
con todos los datos, sintéticos no aportan (0.51 $\rightarrow$ 0.50).

Backtest en test: regla de de-risking frente a buy & hold



Conclusiones

1

Sí, condicionalmente.

La mejora existe con datos escasos y se desvanece con muchos: de +15,7% con 2000 reales a +1,2% con todos (11.336).

2

Ganan quienes reproducen *vol_cartera*.

Ruido y factor mercado + idio la conservan y son los que más ganan. Gaussiano ayuda poco. VAE, GAN y autorregresivo **empeoran**.

3

Sabemos por qué.

La ganancia se explica por la fidelidad en *vol_cartera* (Spearman +), **no** por la curtosis. Lo confirma el factor mercado + idio; los modelos generales no capturan la co-movimiento entre activos.

4

Valor económico en el régimen correcto.

La regla de de-risking reduce riesgo (mejora *Sharpe* y *drawdown*) con datos escasos. El oráculo acota lo alcanzable y fija el techo.



Gracias!